

RAG com HuggingFace

Retrieval Augmented Generation: dando memória factual ao LLM

O PROBLEMA



LLMs alucinam

inventam respostas quando não sabem o fato exato



Conhecimento congelado

só sabem o que viram no treinamento — dados privados ou recentes ficam de fora


A SOLUÇÃO: RAG

Buscar + Gerar

Antes de responder, o sistema **busca documentos relevantes** em uma base de conhecimento e fornece esse contexto ao LLM.

→ *menos alucinação, mais factualidade*

Pipeline RAG em 4 etapas



STACK TECNOLÓGICA

Embeddings

sentence-transformers
all-MiniLM-L6-v2

Vector DB

FAISS
(Facebook AI)

LLM

google/flan-t5-base
(HuggingFace)

Orquestração

LangChain

Resultados e limitações

SEM RAG

Pergunta: "Quanto tempo dura um dia em Marte?"

"Trecente a 22.5 dehu entre 80.00 de ancormance..."

Saída sem sentido — alucinação total.
Nenhum sinal dos números corretos (24h 37min).

COM RAG

Mesma pergunta, agora com contexto recuperado:

"7 Minute intervali ti 24 ou 31 houver de cor"

Saída ainda imperfeita, mas aparecem "24" e "minute" — fragmentos do contexto recuperado (24h e 37min).

LIMITAÇÕES OBSERVADAS E APRENDIZADOS

- 1** FLAN-T5-base é pequeno (250M parâmetros) e treinado em inglês — qualidade limitada em PT-BR
- 2** Mesmo assim, o RAG injetou fragmentos corretos do contexto ("24", "minute") na resposta
- 3** Em produção: usar modelos maiores (Llama 3, Mistral) para resultados confiáveis